

Práctica 2

Transformers en NLP

Resumen automático de noticias: encoder-decoder vs decoder-only



Daniel Ruiz Jiménez

Máster en Data Science — La Salle, Universitat Ramon Llull

Abril de 2026

Índice

Índice	2
1. Introducción	3
1.1 Pregunta central	3
1.2 Metodología iterativa	3
1.3 Hardware.....	3
2. Análisis Exploratorio de Datos	4
2.1 Visión general del dataset	4
2.2 Análisis de tokenización	4
2.3 Decisión sobre max_input_length por modelo	4
3. Diseño de Modelos y Entrenamiento.....	5
3.1 Modelos seleccionados	5
3.2 Decisión de usar T5-base en lugar de T5-large	5
3.3 Preprocesamiento por arquitectura.....	5
3.4 V1 — Baseline zero-shot.....	5
3.5 V2 — Fine-tuning estándar.....	6
Flan-T5-base: full fine-tuning	6
Qwen3-1.7B: LoRA fine-tuning	6
4. Optimización de Hiperparámetros (V3)	7
4.1 Flan-T5-base: resultados.....	7
4.2 Qwen3-1.7B: resultados	7
4.3 Eficiencia comparada	7
5. Evaluación Avanzada	8
5.1 LLM-as-judge	8
5.2 Análisis de errores.....	8
6. Interpretabilidad	9
6.1 Flan-T5-base: cross-attention.....	9
6.2 Qwen3-1.7B: self-attention	9
6.3 Comparativa.....	9
7. Conclusiones	10
7.1 Tabla maestra de evolución.....	10
7.2 Respuesta a la pregunta central	10
7.3 Hallazgos principales.....	10
7.4 Limitaciones	10
7.5 Nota sobre comparabilidad.....	10
7.6 Trabajo futuro	11

1. Introducción

El objetivo de este trabajo es explorar la potencia y limitaciones de los modelos basados en transformers para tareas complejas de NLP, realizando optimización de parámetros, evaluación comparativa y análisis crítico de diferentes arquitecturas. Se espera comprender a fondo la arquitectura, el entrenamiento y la interpretabilidad de los modelos.

La tarea seleccionada es el resumen automático de textos (*abstractive summarization*) sobre el dataset CNN/DailyMail, comparando dos arquitecturas de transformers fundamentalmente distintas: un modelo encoder-decoder clásico (Flan-T5-base, 250M parámetros) y un LLM decoder-only moderno (Qwen3-1.7B, 1.700M parámetros).

1.1 Pregunta central

¿Puede un LLM decoder-only moderno y pequeño (Qwen3-1.7B) adaptado mediante LoRA competir — o incluso superar — a un modelo encoder-decoder diseñado específicamente para tareas seq2seq (Flan-T5-base) con full fine-tuning, en una tarea de resumen abstractivo de noticias?

Esta pregunta tiene relevancia práctica real: los LLMs decoder-only se han convertido en el paradigma dominante, pero los encoder-decoder siguen siendo el estándar histórico para summarization. Saber cuándo merece la pena cada uno informa decisiones de arquitectura en producción.

1.2 Metodología iterativa

Se ha seguido una metodología iterativa con tres versiones principales, replicando el enfoque del proyecto anterior de CNN:

V1 — Baseline zero-shot: inferencia directa de los 4 modelos sin fine-tuning. Establece la línea base y los techos de referencia (BART-large-cnn, Pegasus-cnn_dailymail).

V2 — Fine-tuning estándar: full fine-tuning de Flan-T5-base y LoRA fine-tuning de Qwen3-1.7B con hiperparámetros razonables de primera iteración.

V3 — Optimización y evaluación completa: búsqueda de hiperparámetros (3 configuraciones por modelo), evaluación con LLM-as-judge, interpretabilidad mediante attention maps y análisis de errores.

1.3 Hardware

El entrenamiento se realizó en un ordenador personal con GPU NVIDIA GeForce RTX 5070 (12 GB VRAM, arquitectura Blackwell sm_120), CPU AMD Ryzen 7 9700X y 32 GB DDR5, usando PyTorch con CUDA 12.8. A pesar de disponer de un ordenador con altas prestaciones, surgieron restricciones de VRAM que condicionaron varias decisiones de diseño documentadas a lo largo de esta memoria.

2. Análisis Exploratorio de Datos

2.1 Visión general del dataset

El dataset CNN/DailyMail (versión 3.0.0) contiene más de 300.000 pares artículo-resumen de noticias en inglés. Para este proyecto se trabajó con subsets controlados: 20.000 muestras de train, 1.000 de validación y 1.000 de test.

Propiedad	Valor
Total muestras (subset)	22.000
Artículos: media de palabras	~600
Artículos: máximo	~1.830 palabras
Resúmenes: media de palabras	35–45
Ratio de compresión	5–7%

2.2 Análisis de tokenización

Un hallazgo crítico del EDA fue que cada modelo tokeniza de forma distinta. Se midió la longitud real en tokens sobre 1.000 artículos de train:

Propiedad	Flan-T5	Qwen3
Media (tokens)	850	773
Mediana	748	681
P75	1.094	999
Máximo	2.870	2.833

T5 tokeniza ~10% más tokens que Qwen3 para el mismo texto, debido a la menor eficiencia de su tokenizer SentencePiece frente al BPE moderno de Qwen3.

2.3 Decisión sobre max_input_length por modelo

Dado que cada arquitectura tiene límites de contexto distintos, se configuró max_input_length por modelo en lugar de globalmente:

Modelo	max_input_length	% artículos truncados
Flan-T5-base	512	73,0%
Qwen3-1.7B	1.536	5,6%
BART-large (ref)	1.024	~29%
Pegasus (ref)	1.024	~29%

Implicación crítica: T5 trunca prácticamente 3 de cada 4 artículos, un handicap estructural que ningún fine-tuning puede compensar completamente. Esta asimetría en el acceso a la información del artículo fuente será uno de los ejes del análisis comparativo.

3. Diseño de Modelos y Entrenamiento

3.1 Modelos seleccionados

Modelo	Parámetros	Tipo	Fine-tuning	Contexto
Flan-T5-base	250M	Encoder-decoder	Full (fp32)	512 tokens
Qwen3-1.7B	1.700M	Decoder-only	LoRA r=16	1.536 tokens
BART-large-cnn	400M	Encoder-decoder	Pre-tuned (ref)	1.024 tokens
Pegasus-cnn	568M	Encoder-decoder	Pre-tuned (ref)	1.024 tokens

BART-large-cnn y Pegasus-cnn_dailymail actúan como techos de referencia: son modelos específicamente fine-tuneados sobre CNN/DailyMail y representan el estado del arte práctico para esta tarea.

3.2 Decisión de usar T5-base en lugar de T5-large

Inicialmente se intentó fine-tunear Flan-T5-large (780M parámetros), pero la combinación de tamaño + inestabilidad numérica en bf16 hacía el training inviable en la RTX 5070 (12 GB). La loss arrancaba en valores superiores a 18 (peor que aleatorio con vocabulario de 32K) y el backward pass producía overflow errors. Se cambió a Flan-T5-base (250M), que cabe cómodamente en fp32 con AdamW y además habilita una comparativa más interesante contra Qwen3-1.7B: un encoder-decoder casi 7x más pequeño que el decoder-only.

3.3 Preprocesamiento por arquitectura

Flan-T5-base (seq2seq): tokenización estándar con prefijo "summarize: ", truncado a 512 tokens, padding dinámico gestionado por DataCollatorForSeq2Seq. Labels tokenizados por separado con max_target_length=128.

Qwen3-1.7B (causal): concatenación de prompt + resumen en una sola secuencia. El prompt ("Summarize the following news article:\n\n{article}\n\nSummary:") se tokeniza por separado para enmascarar sus tokens con -100 en los labels, de modo que la loss se compute solo sobre el resumen. Padding a la izquierda (requisito crítico para modelos decoder-only).

3.4 V1 — Baseline zero-shot

Modelo	ROUGE-1	ROUGE-2	ROUGE-L	ROUGE-Lsum	s/muestra
BART-large-cnn (ref)	35,12	14,54	25,54	29,37	0,25
Pegasus-cnn (ref)	34,97	14,35	25,81	31,83	0,34
Flan-T5-base	24,96	9,03	19,17	21,64	0,17
Qwen3-1.7B	22,56	5,29	14,91	18,17	3,09

La jerarquía es coherente: los modelos de referencia especializados marcan el techo; T5-base instruction-tuned queda a ~10 puntos; y Qwen3 zero-shot a ~12 puntos. Qwen3 es notablemente

competitivo en ROUGE-1 (22,56) considerando que es un generalista sin entrenamiento para summarization, pero su ROUGE-2 (5,29) es muy bajo — patrón clásico de los decoder-only que parafrasean en lugar de reproducir n-gramas del estilo periodístico.

Nota: Los scores de BART y Pegasus son ~9 puntos inferiores a los publicados en los papers originales (~44 ROUGE-1). Este gap se debe a: (1) evaluación sobre un subset de 200 muestras, (2) diferencias en el post-procesado específico de los papers, y (3) sensibilidad conocida de ROUGE a detalles de implementación. La comparación relativa entre los cuatro modelos sigue siendo metodológicamente válida.

3.5 V2 — Fine-tuning estándar

Flan-T5-base: full fine-tuning

Configuración: fp32 + AdamW (T5 es inestable en bf16), batch efectivo 16 (per_device=8, grad_accum=2), learning rate 3e-5, 2 epochs sobre 10.000 muestras, gradient checkpointing activado, eval con ROUGE-L al final de cada epoch.

Métrica	V1 zero-shot	V2 fine-tuned	Δ
ROUGE-1	24,96	32,92	+7,96
ROUGE-2	9,03	12,57	+3,54
ROUGE-L	19,17	23,25	+4,08
ROUGE-Lsum	21,64	26,97	+5,33

El fine-tuning aporta +7,96 ROUGE-1, recuperando aproximadamente el 78% del gap respecto al techo BART/Pegasus con solo 10.000 muestras y 2 epochs.

Qwen3-1.7B: LoRA fine-tuning

Configuración: LoRA r=16, alpha=32, dropout=0,05. Target modules: q_proj, k_proj, v_proj, o_proj (solo capas de atención). bf16, batch efectivo 16 (per_device=1, grad_accum=16), learning rate 2e-4, 1 epoch sobre 10.000 muestras. max_input_length reducido a 1.024 durante training (vs 1.536 en inferencia) para caber en VRAM. Parámetros entrenables: 6,4M (0,37% del total).

Métrica	V1 zero-shot	V2 LoRA	Δ
ROUGE-1	22,56	30,44	+7,88
ROUGE-2	5,29	7,78	+2,49
ROUGE-L	14,91	20,53	+5,62
ROUGE-Lsum	18,17	27,84	+9,67

Bug documentado: la primera evaluación post-training produjo tokens degenerados (caracteres chinos, símbolos repetitivos) porque el Trainer dejaba el modelo con gradient_checkpointing=True y use_cache=False, configuración incompatible con beam search. La solución fue recargar el adapter LoRA desde el checkpoint guardado en un estado de inferencia limpio (eval mode + KV cache activado).

4. Optimización de Hiperparámetros (V3)

Se diseñaron 3 configuraciones por modelo, cada una respondiendo a una hipótesis concreta derivada del análisis de V2. El runner de experimentos (experiments.py) soporta reanudación desde checkpoint y skip de experimentos ya completados, permitiendo interrumpir y retomar runs largos sin perder progreso.

4.1 Flan-T5-base: resultados

Config	Datos	Epochs	LR	R-1	R-2	R-L	Tiempo
v3_t5_C	20.000	2	3e-5	33,14	13,00	23,45	755 min
v3_t5_A	10.000	2	3e-5	32,92	12,57	23,25	400 min
v3_t5_B	10.000	3	1e-4	32,63	12,29	22,74	191 min

Más datos fue el factor más importante. Duplicar el training set de 10K a 20K aportó +0,22 ROUGE-1 y +0,43 ROUGE-2, sugiriendo que T5-base no ha saturado y podría seguir mejorando con aún más datos. El learning rate alto (1e-4) resultó contraproducente, generando oscilaciones que impidieron converger.

4.2 Qwen3-1.7B: resultados

Config	Epochs	LR	Rank	Targets	R-1	R-2	R-L	Tiempo
v3_qwen_A	1	2e-4	16	attn	30,41	8,18	20,78	56 min
v3_qwen_C	1	2e-4	16	attn+FFN	30,36	8,00	20,63	575 min
v3_qwen_B	2	1e-4	16	attn	30,68	7,85	20,50	113 min

Resultado sorprendente: la configuración más simple es la mejor. Incluir FFN layers en LoRA triplicó los parámetros entrenables (17,4M vs 6,4M) sin mejora en ROUGE, pero multiplicó el training por 10x (575 vs 56 min). Para summarization con Qwen3-1.7B, las proyecciones de atención capturan prácticamente toda la adaptación necesaria.

La hipótesis de V2 no se confirmó: más epochs + menor LR no mejoró ROUGE-2 (7,85 vs 8,18). El ROUGE-2 bajo en decoder-only parece ser una limitación arquitectónica, no un efecto del entrenamiento.

4.3 Eficiencia comparada

Qwen3 con LoRA es ~12x más eficiente en training que T5-base con full fine-tune (56 min vs 755 min). En ROUGE-L por hora de training, Qwen3 obtiene 22,4 puntos/hora frente a 1,9 de T5. Si el presupuesto de cómputo importa, LoRA sobre un LLM generalista es claramente preferible.

5. Evaluación Avanzada

5.1 LLM-as-judge

Se utilizó Qwen3-1.7B base (sin LoRA) como juez automático local para evaluar 50 resúmenes por modelo en tres dimensiones: coherencia, fidelidad y fluidez (1-5). La elección de un juez local garantiza reproducibilidad completa y elimina dependencias de APIs externas. Se decidió optar por este modelo debido a errores con las APIs de varios LLMs.

Modelo	Coherencia	Fidelidad	Fluidez
Flan-T5-base	4,00	4,18	4,18
Qwen3-1.7B	3,46	3,80	3,76

T5 gana en las tres dimensiones. Un resultado que contradice parcialmente la narrativa de ROUGE: aunque Qwen3 supera a T5 en ROUGE-Lsum (27,75 vs 27,35), el juez lo puntúa significativamente peor en coherencia ($\Delta 0,54$), fidelidad ($\Delta 0,38$) y fluidez ($\Delta 0,42$). De los 2 resúmenes con faithfulness ≤ 2 en todo el dataset, ambos son de Qwen3. En un caso, Qwen3 inventó información no presente en el artículo (alucinación).

ROUGE vs calidad percibida: este análisis confirma que ROUGE no captura la calidad percibida. El estilo telegráfico de Qwen3 ("NEW: X. Y. Z.") maximiza ROUGE-Lsum pero penaliza la lectura natural. Las alucinaciones no afectan a ROUGE pero sí al juez. Para evaluaciones rigurosas, ambas métricas deben usarse juntas.

5.2 Análisis de errores

Se intentó clasificar errores automáticamente (alucinación, omisión, repetición, error factual, sesgo) usando el mismo juez local. El resultado fue que el juez clasificó el 100% de los resúmenes como libres de errores — un resultado que refleja las limitaciones del juez (1,7B), no la perfección de los modelos. Sin embargo, la evidencia cruzada del LLM-as-judge cualitativo (sección 5.1) sí detectó problemas, lo que demuestra que el scoring (1-5) es más sensible que la clasificación binaria para modelos de juez pequeños.

6. Interpretabilidad

6.1 Flan-T5-base: cross-attention

Los heatmaps de cross-attention revelan un patrón claro y consistente: (1) concentración en el primer párrafo, donde CNN/DailyMail típicamente coloca el lead periodístico; (2) picos en entidades nombradas (nombres propios, organizaciones, cifras); (3) alineación monótona diagonal entre tokens generados y posiciones del artículo. El modelo ha aprendido a identificar qué elementos informativos son imprescindibles para un resumen.

6.2 Qwen3-1.7B: self-attention

Los mapas de self-attention del último layer muestran patrones más difusos: atención distribuida sin concentrar en una región del artículo, alta atención en tokens funcionales del prompt, y menor interpretabilidad directa. En un modelo causal, el self-attention mezcla la atención entre tokens del artículo, del prompt y del resumen, lo que dificulta la interpretación comparada con el cross-attention limpio de T5.

6.3 Comparativa

Aspecto	Flan-T5-base	Qwen3-1.7B
Tipo de atención	Cross-attention	Self-attention
Patrón dominante	Concentrado, diagonal	Difuso, distribuido
Foco en entidades	Sí, claramente	Menos marcado
Interpretabilidad	Alta	Media-baja
Sesgo posicional	Primer párrafo	Más uniforme

La arquitectura encoder-decoder ofrece interpretabilidad superior para summarization gracias a la separación limpia de flujos de atención entre fuente y resumen. Esto es una ventaja práctica en contextos donde la explicabilidad importa.

7. Conclusiones

7.1 Tabla maestra de evolución

Modelo	Versión	R-1	R-2	R-L	R-Lsum
BART-large-cnn (ref)	V1 zero-shot	35,12	14,54	25,54	29,37
Pegasus-cnn (ref)	V1 zero-shot	34,97	14,35	25,81	31,83
Flan-T5-base	V3 best (C)	33,14	13,00	23,45	27,35
Flan-T5-base	V2 fine-tuned	32,92	12,57	23,25	26,97
Flan-T5-base	V1 zero-shot	24,96	9,03	19,17	21,64
Qwen3-1.7B	V3 best (A)	30,41	8,18	20,78	27,75
Qwen3-1.7B	V2 LoRA	30,44	7,78	20,53	27,84
Qwen3-1.7B	V1 zero-shot	22,56	5,29	14,91	18,17

7.2 Respuesta a la pregunta central

La respuesta es: depende de qué se mida. En métricas léxicas (ROUGE-1, ROUGE-L), Flan-T5-base gana pese a ser 7x más pequeño. En estructura narrativa (ROUGE-Lsum), Qwen3 gana ligeramente. En calidad percibida (LLM-judge), T5 gana en las tres dimensiones. En eficiencia de training, Qwen3 con LoRA es 12x más rápido.

7.3 Hallazgos principales

- 1. El fine-tuning aporta ~8 puntos de ROUGE-1** en ambas familias, con solo 10–20K muestras. El grueso de la mejora viene del fine-tuning en sí, no de la optimización de hiperparámetros (+0,2 ROUGE-L adicional en V3).
- 2. La ventana de contexto es un factor dominante pero no decisivo.** T5 trunca el 73% de los artículos; Qwen3 solo el 5,6%. Pese a ello, T5 gana, lo que sugiere que su arquitectura encoder-decoder compensa la pérdida de contexto con mayor eficiencia de procesamiento.
- 3. ROUGE y calidad percibida no correlacionan perfectamente.** Qwen3 gana en ROUGE-Lsum pero pierde en las tres dimensiones del LLM-judge. La evaluación multi-dimensional es imprescindible.
- 4. LoRA sobre FFN layers no aporta valor en esta tarea.** Triplicar los parámetros entrenables incluyendo gate/up/down_proj no mejoró ROUGE y multiplicó el tiempo de training por 10x.

7.4 Limitaciones

Subset de 200 muestras para evaluación (varianza de $\pm 2-3$ puntos). Un solo dataset (CNN/DailyMail): no se puede generalizar a otros dominios. Juez automático de 1,7B: limitado para detectar errores sutiles. Comparación no puramente arquitectónica: se mezclan efectos de arquitectura, tamaño de contexto, tamaño del modelo y estrategia de fine-tuning.

7.5 Nota sobre comparabilidad

Es importante notar que esta comparación no aísla el impacto de la arquitectura (encoder-decoder vs decoder-only) del impacto del tamaño de contexto, el número de parámetros o la

estrategia de fine-tuning. Se trata de una comparación práctica entre dos modelos representativos de cada familia, tal como están disponibles en su forma pre-entrenada estándar. Una comparación puramente arquitectónica requeriría controlar cada una de estas variables por separado, lo cual queda fuera del alcance de este trabajo.

7.6 Trabajo futuro

Ampliar evaluación al test set completo (~11.500 muestras). Probar Qwen3-4B con QLoRA para evaluar el efecto del tamaño del decoder-only. Evaluar en un segundo dataset (XSum, ArXiv) para generalización. Incorporar evaluación humana para validar el LLM-judge. Explorar T5 con contexto extendido (Longformer-Encoder-Decoder) para aislar el efecto de la ventana de contexto. Utilizar un modelo separado e independiente como LLM-judge.